VAE 全流程：模型表示、学习、推断及测试评估

目录

1 引入 **2**

2 表示 **2**

3 学习 **3**

4 推断：引入变分分布与 ELBO **3**

4.1 变分思想：用可控的 $q_\phi(z \mid x)$ 近似不可得的后验 3

4.2 如何定义“逼近得最好”？——最小化后验 KL。 3

4.3 常见推导 5

5 具体网络训练 **6**

5.1 摊销推断：用编码器参数化 $q_\phi(z \mid x)$ 6

5.2 解码器参数化：$p_\theta(x \mid z)$ 6

5.3 小批量训练：把期望写成 Monte Carlo 估计 7

5.4 θ 的梯度：交换梯度与期望 + 采样近似 7

5.5 ϕ 的梯度难点：采样节点阻断梯度 7

5.6 重参数化技巧：把随机性移到与 ϕ 无关的噪声上 8

5.7 KL 项的闭式：高斯对标准高斯 9

5.8 训练流程小结 9

6 测试与评估 **9**

6.1 测试时生成 9

6.2 测试时评估 9

6.3 补充：重构 10

7 引用 **10**

1 引入

在 GMM 里，我们通常用一个离散隐变量 $z \in \{1, \ldots, K\}$ 表示“属于哪个簇”，并用 K 个高斯分量混合来拟合观测的边缘分布 $p(x)$。把它写成隐变量形式时，就是

$$p(x) = \sum_{k=1}^{K} p(x \mid z = k)\, p(z = k).$$

现在考虑一个更复杂的任务：手写数字图像的生成。把一张 28×28 的图片展平成向量后，$x \in \mathbb{R}^{784}$。直觉上我们会觉得数据是**多峰**的：例如“0”、“1”、...、“9”的样本大致各自聚在不同区域。于是一个最简单的想法是取 $K = 10$，用混合高斯去建模。

但这个想法往往并不 work。原因在于：即便固定为同一个数字（例如都是“0”），它内部仍然存在大量模式差异——不同写法的“0”、不同书写风格、不同位置（在图像左边写一个“0” vs 在右边写一个“0”）都会造成显著的分布变化。换句话说：**不仅类别之间是多峰的，类别内部也有多峰结构**。当数据维度很高时，这种“峰”的数量会急剧增加，使得用任何有限的 K 去覆盖都变得困难。

因此我们希望引入一个更灵活的机制：不要预先固定“到底有多少个分量”，而是让模型能够对应**不可数无穷多个分量**。

2 表示

实现方式是把离散的簇标签 z 推广为一个**连续且高维**的变量 $z \in \mathbb{R}^d$，这里的关键是不再把 z 理解成 GMM 里的“簇编号”，而是把 z 理解成一组**潜在属性**：它可以是高维的，其中一些维度可能刻画“它更像哪个数字”，一些维度刻画亮度、倾斜、位置、书写风格等，也可能包含少量不具备明确物理意义的随机细节。此时，离散求和自然推广为积分边缘化，得到一个统一的核心公式：

$$p_\theta(x) = \int p_\theta(x \mid z)\, p(z)\, \mathrm{d}z. \tag{1}$$

- $p(z)$**：**先验，通常是**我们事先指定且已知的**简单、易采样的分布，比如标准高斯 $\mathcal{N}(0, I)$；
- **条件分布** $p_\theta(x \mid z)$**：**由于真实的条件分布 $p^*(x \mid z)$ 往往未知且难以直接刻画，对固定的 z，我们可以把 $p_\theta(x \mid z)$ 定义为一个简单的分布族（例如高斯/伯努利），其均值（以及方差）由一个神经网络从 z 映射得到。

在上述设定下，给定一个具体的 z 与参数 θ，我们就得到一个明确的简单条件分布 $p_\theta(x \mid z)$；而由于 z 是连续变量，积分边缘化相当于在 x 空间中组合了不可数无穷多个这样的“简单分量”，从而使得整体分布 $p_\theta(x)$ 可以非常复杂、表达能力很强——即便 $p(z)$ 与单个 $p_\theta(x \mid z)$ 本身都很简单。比如两者都是高斯的时候，由于 $\mu_\theta(z)$ 与 $\Sigma_\theta(z)$ 由神经网络给出并随 z 呈强非线性变化，边缘化

$$p_\theta(x) = \int \mathcal{N}\big(x; \mu_\theta(z), \Sigma_\theta(z)\big)\, p(z)\, \mathrm{d}z$$

等价于对不可数无穷多个、且参数随 z 非线性变化的高斯分量进行连续混合（除非处在线性高斯这类特殊情形 (如 $\mu_\theta(z) = Az + b$, $\Sigma_\theta(z) = const$), 否则该积分一般不会是高斯），最后得到的是一个非常复杂的分布，从而有了更强大的表达能力。

因此，“表示”部分的核心含义是：**我们用简单先验 $p(z)$ 作为隐空间的基准结构，用解码器 $p_\theta(x \mid z)$ 把隐空间映射到数据空间**。

3 学习

理想目标是最大化训练数据的对数似然：

$$\max_\theta \ \log p_\theta(x) = \max_\theta \ \log \int p_\theta(x \mid z)\, p(z)\, \mathrm{d}z. \tag{1}$$

式 (1) 的难点在于这个积分要遍历所有的 z。当 z 是低维的时候，可能我们能直接积分出来，但当处于高维空间的时候，此时计算机积分会通过采样来近似，对于一张图片，绝大多数 z 都是“噪声”，生成的都是乱码，只有极少数 z 能生成这张图，计算复杂且低效。因此，想高效、有效地学习，就必须知道对于给定的 x，哪些 z 是重要的，也就是要知道后验分布 $p_\theta(z \mid x)$, 但是

$$p_\theta(z \mid x) = \frac{p_\theta(x, z)}{p_\theta(x)} = \frac{p_\theta(x \mid z) p(z)}{\int p_\theta(x \mid z) p(z) \mathrm{d}z}, \tag{2}$$

由于积分难算，模型真实后验也随之不可得。但我们有一种变分推断的方法可以解决这一问题。

4 推断：引入变分分布与 ELBO

4.1 变分思想：用可控的 $q_\phi(z \mid x)$ 近似不可得的后验

变分推断的核心是：在一个**可控**、**好算**的分布族 $\mathcal{Q}$ 中，选择一个分布去近似真实后验。这就是“变分”的含义：优化的对象不是一个数，而是一个**分布（函数）**。具体过程如下图所示。具体到 VAE，我们用编码器参数化这个分布：

$$q_\phi(z \mid x) \in \mathcal{Q}, \qquad q_\phi(z \mid x) \approx p_\theta(z \mid x), \tag{3}$$

其中 ϕ 为编码器参数。一般这个分布族尽量选一些好采样的（便于后续 decoder 的进行），这就把原来的积分转化为了一个优化的问题。

4.2 如何定义“逼近得最好”？——最小化后验 KL。

我们希望 $q_\phi(z \mid x)$ 尽可能贴近真实后验 $p_\theta(z \mid x)$，一个标准度量是

$$\mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p_\theta(z \mid x)\big) = \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{q_\phi(z \mid x)}{p_\theta(z \mid x)} \right]. \tag{4}$$

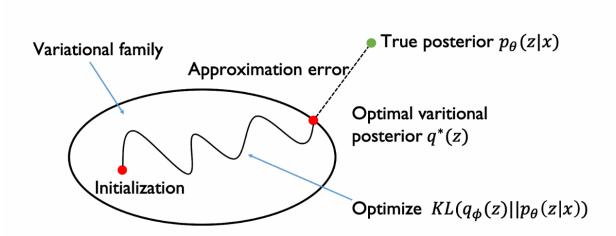

图 1: 变分

代入 $p_\theta(z \mid x) = \frac{p_\theta(x,z)}{p_\theta(x)}$:

$$\mathrm{KL}(q_\phi \| p_\theta) = \mathbb{E}_{q_\phi}\left[\log q_\phi(z \mid x) - \log p_\theta(x,z) + \log p_\theta(x)\right] \tag{5}$$

$$= \log p_\theta(x) - \mathbb{E}_{q_\phi}\left[\log p_\theta(x,z) - \log q_\phi(z \mid x)\right]. \tag{6}$$

整理得到恒等式:

$$\boxed{\log p_\theta(x) = ELBO(\theta,\phi;x) + \mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p_\theta(z \mid x)\big)} \tag{7}$$

- $\mathrm{KL}(\cdot\|\cdot) \geq 0$，因此 $ELBO(\theta,\phi;x) \leq \log p_\theta(x)$，ELBO 确实是 log 似然的下界;
- “下界与目标之间的差距” 正是 $\mathrm{KL}(q_\phi(z \mid x)\|p_\theta(z \mid x))$。

我们得到了一个似然的替换式，但由于真实后验 $p_\theta(z \mid x)$ 是未知的，所以我们也没法直接把式子右侧当做新的优化目标。怎么办呢？这是我们可以回顾一下，我们现在相当于有两个任务，我们的主任务是最大似然，也就是优化 θ，但是因为直接优化困难，所以又引入一个子任务——最小化变分分布 ϕ 和真实后验的 KL 散度。基于回顾，我们再观察上面式子可得:

A. 对 ϕ (变分参数) 来说: 最小化那个 KL 等价于优化 ELBO
因为 $\log p_\theta(x)$ 不含 ϕ, 所以对固定 θ:

$$\arg\max_\phi \mathrm{ELBO}(\theta,\phi) \quad \Longleftrightarrow \quad \arg\min_\phi \mathrm{KL}(q_\phi(z \mid x)\|p_\theta(z \mid x))$$

B. 对 θ (生成模型参数) 来说: ELBO 是 $\log p_\theta(x)$ 的可计算下界
因为 $\mathrm{KL} \geq 0$, 所以

$$\mathrm{ELBO}(\theta,\phi) \leq \log p_\theta(x)$$

我们真正想最大化的是 $\log p_\theta(x)$, 但它不可算; 于是最大化一个” 紧的下界” 就是标准替代目标:

- ϕ 步: 把下界” 拉紧” (减小 gap = KL，等价于逼近真实后验)
- θ 步: 把下界” 抬高” (提高数据似然的下界，从而间接提高 $\log p_\theta(x)$)

至此，我们可以得出结论：**只优化 ELBO 既是在抬高可计算下界，也是在逼近真实后验**，我们只需要优化这个**可计算**、**可优化**的 ELBO 就行了，并且把问题转化为了对 ELBO 的双优化问题

$$\max_{\theta}\left\{\max_{\phi}\mathrm{ELBO}(\theta,\phi)\right\}$$

4.3 常见推导

这里再提供两种常见的推导方式，第一种引入 ϕ 和后续推导的思路可以理解为凑那个 KL 的过程，第二种引入 ϕ 和后续推导的思路可以理解为是一种重要性采样。把联合分布

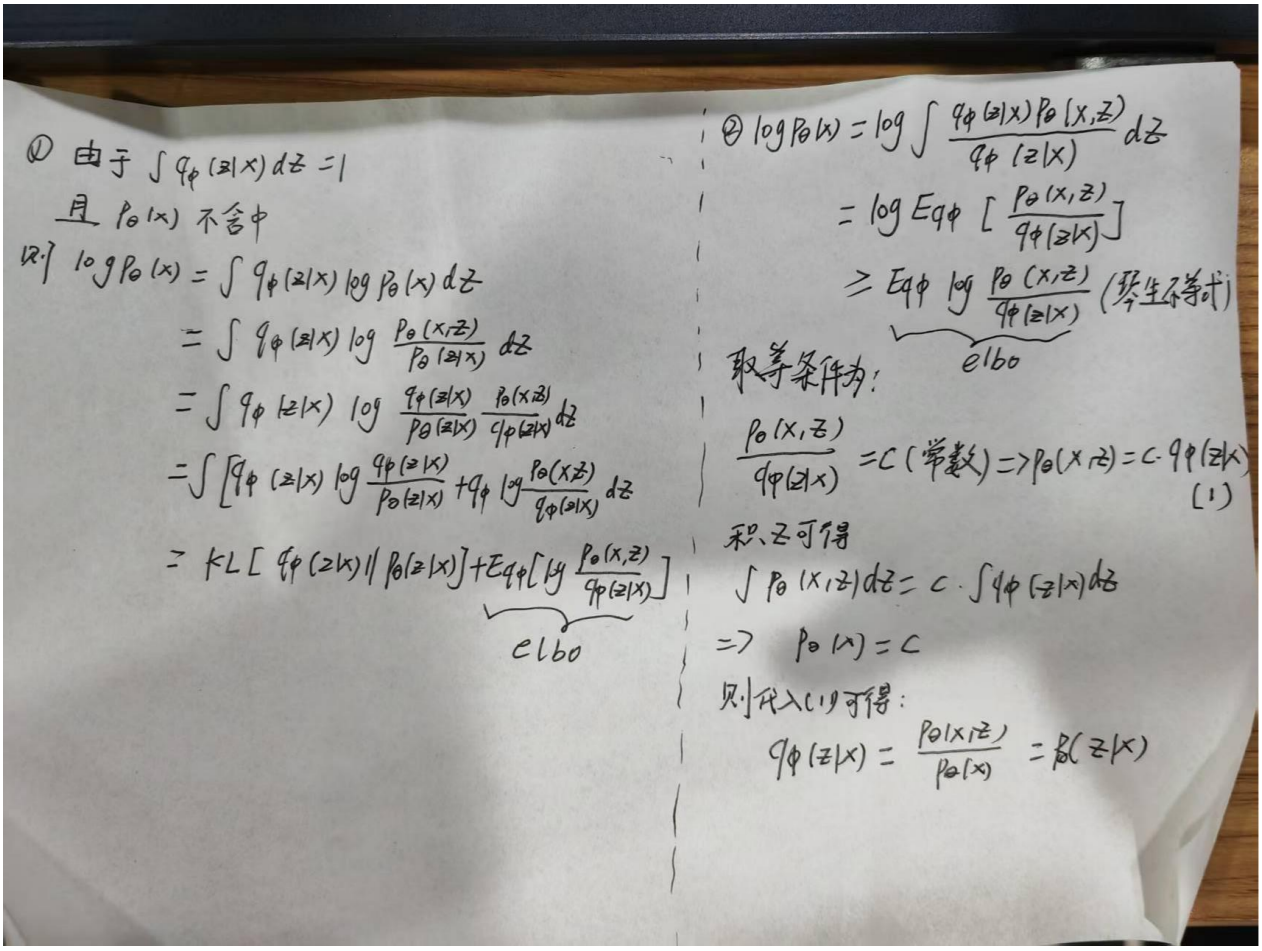

图 2: 推导补充

$p_\theta(x,z)=p_\theta(x\mid z)p(z)$ 代入 ELBO 定义 (7)到常见分解：

$$\boxed{\log p_\theta(x)=\underbrace{\mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x\mid z)\big]}_{\text{重构项}}-\underbrace{\mathrm{KL}\big(q_\phi(z\mid x)\,\|\,p(z)\big)}_{\text{正则项}}+\underbrace{\mathrm{KL}\big(q_\phi(z\mid x)\,\|\,p_\theta(z\mid x)\big)}_{\text{后验差距}}} \tag{8}$$

这三项分别对应：

- **重构项** $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x\mid z)]$：鼓励解码器（这里可以先看一下下一节的图，知道一下 encoder 和 decoder 的对应关系）在从 $q_\phi(z\mid x)$ 采样的 z 上，能够高概率重构观测 x。

- **正则项** $-\mathrm{KL}(q_\phi(z \mid x) \| p(z))$：限制编码器输出不要偏离先验太远，**使来自训练数据的潜变量整体分布趋近先验，从而支持从先验采样进行生成**，同时作为正则项也可以限制过拟合。

- **后验差距（gap）** $+\mathrm{KL}(q_\phi(z \mid x) \| p_\theta(z \mid x))$：刻画近似后验与真实后验的距离，也是 $\log p_\theta(x)$ 与 ELBO 的差；由于该项非负，最大化 ELBO 等价于在抬高下界的同时尽量缩小这一差距。

5 具体网络训练

上一节我们已经得到一个统一且可优化的目标 ELBO：对每个样本 x，

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x \mid z)\big] - \mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p(z)\big), \tag{9}$$

但如何把式 (9) 变成两个神经网络（encoder/decoder）的可执行训练过程?

5.1 摊销推断：用编码器参数化 $q_\phi(z \mid x)$

由于每个 x 对应的 z 所在的区域不同，我们的设计就必须满足每个 x 能求出它对应的 z 的分布，但对每个训练样本都单独拟合一个变分分布 $q(z|x)$ 在计算上不现实, 因此采用 “摊销” 思想: 用同一个编码器网络对所有样本共享参数。所以相当于，有 n 个样本，用同一个参数的 encoder 得到它们各自对应的 n 个 z 分布，我们令编码器输出变分分布的参数, 例如最常用的对角高斯:

$$q_\phi(z \mid x) = \mathcal{N}\big(z\,;\, \mu_\phi(x), \mathrm{diag}(\sigma_\phi^2(x))\big), \tag{10}$$

其中 $\mu_\phi(x)$ 与 $\sigma_\phi(x)$ 由神经网络计算得到。

5.2 解码器参数化：$p_\theta(x \mid z)$

解码器是生成网络, 输入 z 输出观测分布的参数。这个分布是可以根据任务变化的, 例如:

- 若 x 为二值图像，可用 Bernoulli：$p_\theta(x \mid z) = \mathrm{Bernoulli}(x; \pi_\theta(z))$；

- 若 x 为连续值，可用 Gaussian：$p_\theta(x \mid z) = \mathcal{N}(x; \mu_\theta(z), \Sigma_\theta(z))$。

至此，VAE 就对应两张网络：encoder $q_\phi(z \mid x)$ 与 decoder $p_\theta(x \mid z)$，共享同一个目标 (9)，流程如下图。

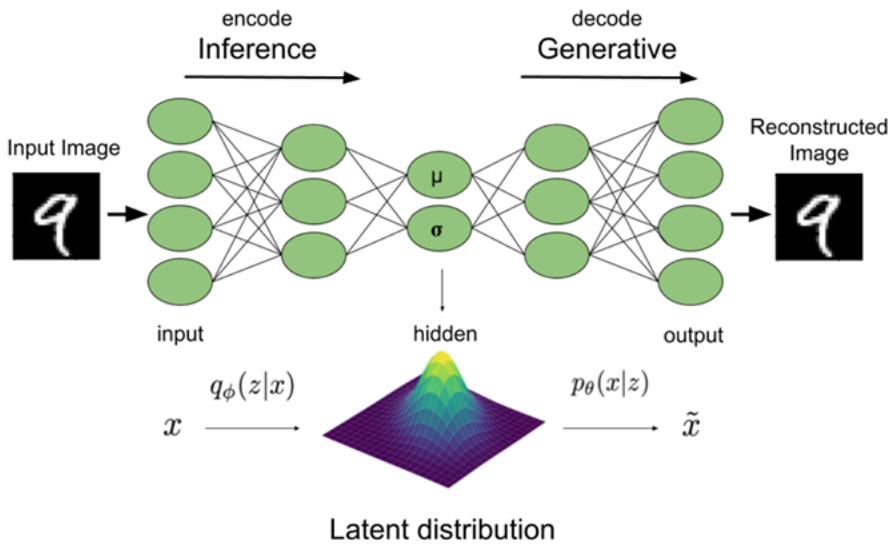

图 3: VAE 流程示意图

5.3 小批量训练：把期望写成 Monte Carlo 估计

式 (9) 的第一项是关于 $q_\phi(z \mid x)$ 的期望，一般不好积分，通常用采样近似：

$$\mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x \mid z)\big] \approx \frac{1}{K}\sum_{k=1}^{K} \log p_\theta\big(x \mid z^{(k)}\big), \qquad z^{(k)} \sim q_\phi(z \mid x). \tag{11}$$

训练时再配合小批量 $\mathcal{B}$，优化负 ELBO 损失：

$$\mathcal{J}(\theta, \phi; \mathcal{B}) \triangleq -\frac{1}{|\mathcal{B}|}\sum_{x \in \mathcal{B}} \mathcal{L}(\theta, \phi; x). \tag{12}$$

5.4 θ 的梯度：交换梯度与期望 + 采样近似

对 θ 而言，$q_\phi(z \mid x)$ 不含 θ，因此可将梯度与期望交换：

$$\nabla_\theta \mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x \mid z)\big] = \mathbb{E}_{q_\phi(z|x)}\big[\nabla_\theta \log p_\theta(x \mid z)\big] \approx \frac{1}{K}\sum_{k=1}^{K} \nabla_\theta \log p_\theta\big(x \mid z^{(k)}\big). \tag{13}$$

同时，$\mathrm{KL}(q_\phi(z \mid x) \| p(z))$ 项不含 θ，因此 θ 的梯度整体较直接。

5.5 ϕ 的梯度难点：采样节点阻断梯度

对 ϕ 的问题在于：$z^{(k)} \sim q_\phi(z \mid x)$ 的“采样”看似不可导，直接对 (11) 求导会遇到“梯度穿不过随机节点”的困难。一种通用但方差很大的做法是用 REINFORCE：令

$$f(z, \phi) \triangleq \log p_\theta(x, z) - \log q_\phi(z \mid x),$$

$$
\begin{aligned}
\nabla_\phi \mathcal{L}(\theta,\phi;x) &= \mathbb{E}_{q_\phi(z|x)}\big[f(z,\phi)\,\nabla_\phi \log q_\phi(z\mid x)\big] \;+\; \mathbb{E}_{q_\phi(z|x)}\big[\nabla_\phi f(z,\phi)\big] \\
&= \mathbb{E}_{q_\phi(z|x)}\Big[\big(\log p_\theta(x,z) - \log q_\phi(z\mid x)\big)\,\nabla_\phi \log q_\phi(z\mid x)\Big] \;+\; \mathbb{E}_{q_\phi(z|x)}\big[-\nabla_\phi \log q_\phi(z\mid x)\big].
\end{aligned} \tag{14}
$$

$$
\mathbb{E}_{q_\phi(z|x)}\big[\nabla_\phi \log q_\phi(z\mid x)\big] = \int q_\phi(z\mid x)\,\nabla_\phi \log q_\phi(z\mid x)\,\mathrm{d}z = \int \nabla_\phi q_\phi(z\mid x)\,\mathrm{d}z = \nabla_\phi 1 = 0, \tag{15}
$$

因此 (14) 的第二项为 -0，可被消去，最终得到常见的单项形式：

$$
\nabla_\phi \mathcal{L}(\theta,\phi;x) = \mathbb{E}_{q_\phi(z|x)}\Big[\big(\log p_\theta(x,z) - \log q_\phi(z\mid x)\big)\,\nabla_\phi \log q_\phi(z\mid x)\Big]. \tag{16}
$$

但在 VAE 中更常用、更稳定的是**重参数化技巧**。

5.6 重参数化技巧：把随机性移到与 ϕ 无关的噪声上

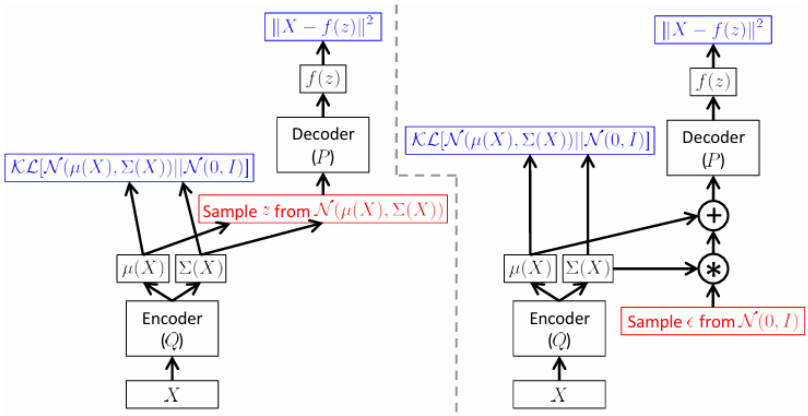

图 4: 重参数化

当 $q_\phi(z\mid x)$ 为连续可重参数化分布（如高斯）时，我们引入与 ϕ 无关的噪声

$$
\epsilon \sim \mathcal{N}(0,I), \tag{17}
$$

并令

$$
z = g_\phi(x,\epsilon) \triangleq \mu_\phi(x) + \sigma_\phi(x)\odot\epsilon. \tag{18}
$$

这样 $z\sim q_\phi(z\mid x)$ 仍成立，但期望可以改写为对固定噪声分布的期望：

$$
\mathbb{E}_{q_\phi(z|x)}\big[\log p_\theta(x\mid z)\big] = \mathbb{E}_{\epsilon\sim\mathcal{N}(0,I)}\Big[\log p_\theta\big(x\mid g_\phi(x,\epsilon)\big)\Big]. \tag{19}
$$

好处是：(19) 中的随机性来自 ϵ，与 ϕ 无关，因此可以把梯度“穿过”g_ϕ 做标准反向传播：

$$
\nabla_\phi \mathbb{E}_\epsilon\Big[\log p_\theta\big(x\mid g_\phi(x,\epsilon)\big)\Big] = \mathbb{E}_\epsilon\Big[\nabla_\phi \log p_\theta\big(x\mid g_\phi(x,\epsilon)\big)\Big] \approx \frac{1}{K}\sum_{k=1}^{K}\nabla_\phi \log p_\theta\big(x\mid g_\phi(x,\epsilon^{(k)})\big). \tag{20}
$$

5.7 KL 项的闭式：高斯对标准高斯

当 $q_\phi(z \mid x)$ 为对角高斯、$p(z) = \mathcal{N}(0, I)$ 时，KL 项可解析：

$$\mathrm{KL}\big(q_\phi(z \mid x) \,\|\, p(z)\big) = \frac{1}{2} \sum_{j=1}^{d} \Big(\mu_{\phi,j}(x)^2 + \sigma_{\phi,j}(x)^2 - \log \sigma_{\phi,j}(x)^2 - 1 \Big), \tag{21}$$

从而避免再对 KL 做采样估计，进一步降低方差并稳定训练。

5.8 训练流程小结

将以上各步合并，VAE 的一次小批量迭代可表述为：

1. 从数据集中采样一个小批量 $\mathcal{B}$；
2. 对每个 $x \in \mathcal{B}$，编码器输出 $\mu_\phi(x), \sigma_\phi(x)$；
3. 采样 $\epsilon^{(k)} \sim \mathcal{N}(0, I)$，构造 $z^{(k)} = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon^{(k)}$；
4. 计算重构项 $\frac{1}{K} \sum_k \log p_\theta(x \mid z^{(k)})$ 与 KL 项 (21)；
5. 得到损失 $\mathcal{J}(\theta, \phi; \mathcal{B})$，用（随机）梯度下降/Adam 同时更新 θ, ϕ。

6 测试与评估

核心包括两件事：一是如何在测试时生成新样本；二是如何对给定测试样本 x 评估模型的拟合程度。

6.1 测试时生成

在测试阶段，如果我们希望从模型生成新的样本，只需要移除编码器，直接从先验中采样潜变量并输入解码器：

$$z \sim p(z) = \mathcal{N}(0, I), \qquad x \sim p_\theta(x \mid z). \tag{22}$$

直观地说：先验 $p(z)$ 提供一个可采样的“隐空间坐标系”，解码器 $p_\theta(x \mid z)$ 将该坐标映射到数据空间，从而得到新的样本。

6.2 测试时评估

$p_\theta(x)$ 一般不可直接计算，但 ELBO 是 $\log p_\theta(x)$ 的一个可计算下界。虽然 ELBO 中仍包含对 $z \sim q_\phi(z \mid x)$ 的期望，但这可以用采样近似，并且**从 $q_\phi(z \mid x)$ 采样通常比从 $p(z)$ 采样收敛更快**（因为 q_ϕ 会把概率质量集中在更“能解释该样本 x”的 z 区域）。因此，在实践中 ELBO 可作为测试时衡量模型对单个样本拟合程度的一个有效指标：ELBO 越大，其下界意义下的对数似然越高，说明模型对该样本的解释越充分。

6.3 补充：重构

除了从先验生成样本外，还可以对测试样本进行重构：先用编码器得到 $z \sim q_\phi(z \mid x)$，再用解码器生成 $\hat{x} \sim p_\theta(x \mid z)$。与直接的重构误差相比，ELBO 同时考虑了重构项与潜空间正则项（KL），因此更能反映“该样本是否在模型的可解释范围内”。

7 引用

https://www.bilibili.com/video/BV1Lx4y1v7fF/?spm$_i d_f rom = 333.1387.collection.video_c ard.click$

https://arxiv.org/abs/1606.05908

https://kuleshov.github.io/cornell-deep-generative-models-course/assets/slides/lecture5.pdf

https://kuleshov.github.io/cornell-deep-generative-models-course/assets/slides/lecture6.pdf